Planteo del problema

PrestaMatch, es una plataforma financiera Peer-to-Peer (P2P), que actúa como intermediaria: recibe dinero de inversores y se lo presta a solicitantes. Como parte del equipo de Data Science, nuestro objetivo fue estimar la probabilidad de que una solicitud de préstamo sea aprobada o rechazada, y utilizar esa estimación para priorizar las operaciones con mejor Retorno de Inversión (ROI) esperado. Se asignó como presupuesto máximo 2.000.000 USD para otorgar a los nuevos préstamos. Este problema se abordó en dos etapas: primero se realizó un modelo de clasificación para estimar riesgo de cada solicitud y luego una regla de decisión financiera que selecciona préstamos sin superar el presupuesto máximo disponible.

Datos de entrada - Datasets

Se trabajó con 3 datasets, que brindaban diferentes datos: solicitudes_train con 32.416 solicitudes; solicitudes_test con 3.061 solicitudes y comportamiento_bancario con el historial mensual de 28.993 usuarios.

Se unieron solicitudes_train y solicitudes_test para que las variables que se calcularon sean sobre todas las solicitudes. Para tener más información sobre los usuarios de cada solicitud, se vinculó el historial bancario con la solicitudes mediante “ID_Usuario” y se conservaron únicamente los registros cuyo “Mes_Referencia” fuera anterior a la “Fecha_Solicitud”. Este corte evita incorporar información posterior o información del “futuro”a la decisión de otorgar o no el préstamo, para evitar data leakage. El historial se procesó por solicitud, en orden cronológico. A partir de él se crearon variables que resumen el nivel y la evolución de los saldos y atrasos: promedios, desviación estándar, último valor disponible, proporción de meses con atraso, máximos y promedios de los últimos 3 y 6 meses, tendencia reciente de saldos y atrasos, coeficiente de variación del saldo y racha de meses consecutivos sin atrasos. También se incorporaron variables de la solicitud y se transformó la variable “Motivo_Prestamo” mediante one-hot encoding.

Se excluyeron de las entradas del clasificador los identificadores, la fecha, la etiqueta objetivo, Monto_Solicitado y dos variables derivadas del monto (“Monto_sobre_Ingreso” y “Monto_sobre_Saldo”). El monto se reserva para el cálculo posterior de retorno y presupuesto.

Entrenamiento y validación

La separación se hizo temporalmente: solicitudes anteriores al 1 de octubre de 2025 para entrenamiento y solicitudes desde esa fecha para validación. Además, se excluyeron de validación los usuarios presentes en entrenamiento, simulando la evaluación sobre personas nuevas.

El modelo principal fue HistGradientBoostingClassifier, con un aprendizaje que sea más gradual y controlado (learning_rate = 0,05), un máximo de iteraciones (max_iter = 300), que la profundidad máxima de cada árbol sea 3 niveles (max_depth = 3), se aplicó una penalización para evitar que el modelo se vuelva demasiado complejo (l2_regularization = 1) y la semilla aleatoria (random_state=42). Se utilizó AUC-ROC porque permite evaluar la capacidad de ordenar casos con mayor o menor probabilidad de pago sin fijar un umbral único.

Además del AUC, simulamos la decisión de negocio sobre validación: se descartan montos > 11.000 USD (rango del test) y se asigna un presupuesto proporcional (2.000.000 / demanda total del test). Se repite la evaluación con tres cortes (01/07 (julio), 01/09 (septiembre) y 01/10 (octubre)) para no depender de una única partición.

Se evalúa con el split temporal y luego se re-entrena con todo el train para predecir el test.

Conjunto	Resultado
Validación (corte 01/10)	Con el límite de 2.000.000 USD, se aprobaron 285 préstamos, con un capital invertido de 1.999.800 USD. La tasa de defaults entre los aprobados fue del 0,4 % y la ganancia real observada fue de 533.605 USD. El AUC de la evaluación del modelo fue 0,8586. También se probó la etapa de validación del modelo sin el límite de dinero y los resultados fueron: la cantidad de préstamos aprobados fue 462, el capital invertido fue de 3.078.700 USD, la tasa de defaults entre los aprobados fue del 1,1% y la ganancia fue de 779.153 USD, con un AUC de validación de 0,8586. Claramente la diferencia se ve en el total de capital invertido y en las ganancias; pero el AUC es el mismo. El archivo final conserva la primera validación.
Test	Se aprobaron 767 préstamos, con un capital total de 1.995.100 USD, dentro del presupuesto disponible. La ganancia neta proyectada fue de 498.427 USD. El puntaje informado en Kaggle para aproximadamente el 30 % del test fue de 149.641 USD.

Con la política de ROI y presupuesto implementada, el principal costo es de oportunidad, ya que en validación se rechazaron 1.058 clientes que habrían pagado, debido a que el presupuesto disponible no alcanza para aprobar todas las solicitudes. Por otro lado, el error más costoso, correspondiente a aprobar préstamos que terminan en default, se limitó a 4 casos.

Para tomar las decisiones no se utilizó un umbral fijo de 0,5 sobre la probabilidad de pago, sino que se calculó la ganancia esperada de cada solicitud, considerando que un pago exitoso permite recuperar el capital más los intereses. Luego, se dividió la ganancia esperada por el monto solicitado para obtener el ROI esperado. Se descartaron las solicitudes con un ROI esperado menor o igual al 2 % y aquellas que superan el monto de USD 11.000 por préstamo. Las restantes se ordenaron de mayor a menor ROI esperado y se aprobaron siguiendo ese orden hasta alcanzar el presupuesto total disponible de USD 2.000.000, sin superar dicho límite. Cuando se hace referencia a la ganancia proyectada es una esperanza calculada a partir de las probabilidades estimadas por el modelo y no una ganancia observada en la práctica.

Otros enfoques probados que fueron probados y descartados

Se probaron modelos con Random Forest (RF), regresión logística, un ensamble que promedia las probabilidades de Random Forest y HistGradientBoosting, y profundidades de árbol de 3, 4 y 8.

Los promedios de los tres cortes utilizados (julio, septiembre y octubre) para la simulación económica fueron:

Modelo	AUC medio	Default entre aprobados	Ganancia / USD invertido
HistGradientBoosting	0,842	1,4 %	0,248
Random Forest	0,843	1,5 %	0,246
Regresión logística	0,845	1,3 %	0,243
Ensamble HGB + RF	0,844	1,4 %	0,248

max_depth (profundidad máxima)	AUC medio	Brecha	Defaults entre aprobados	Ganancia / USD invertido
3	0,844	0,005	0,014	0,248
4	0,843	0,013	0,015	0,247
8	0,842	0,039	0,014	0,248

La regresión logística obtuvo un AUC medio levemente mayor, pero no logró la mejor ganancia por dólar. El ensamble no mejoró la rentabilidad respecto de HistGradientBoosting, por lo que se prioriza un único modelo con retorno comparable.

La prueba de profundidad mostró que max_depth = 3 reducía la brecha media entre entrenamiento y validación (0,005 frente a 0,039 para profundidad 8), con AUC y ganancia muy similares. Por esta razón se eligió conservar como máximo de profundidad de los árboles 3 niveles, permitiendo encontrar un equilibrio entre el rendimiento del modelo y su capacidad de generalización. En las pruebas realizadas, una profundidad menor indicó un menor riesgo de overfitting (sobreajuste).

Conclusión

A lo largo del proyecto pudimos desarrollar un modelo que ayuda a seleccionar préstamos teniendo en cuenta la probabilidad de pago y la ganancia esperada. Entre diferentes alternativas, la elegida fue HistGradientBoosting, ya que obtuvo buenos resultados sin mostrar tanta diferencia entre el entrenamiento y la validación.

Sin embargo, durante el análisis encontramos algunas limitaciones. Una de las principales es la diferencia en la distribución de los montos entre los datos de entrenamiento y los de prueba, que puede afectar la capacidad del modelo para generalizar. Además, las probabilidades que predice no siempre coinciden con las tasas de pago reales. Por ejemplo, para préstamos de hasta 3.000 USD, el modelo predice una probabilidad media de pago del 86,1 %, mientras que la tasa real fue del 88,1 %. Esto muestra que todavía sería necesario mejorar la calibración de las probabilidades.

Por otro lado, el umbral de rentabilidad del 2 % y el método utilizado para elegir los préstamos son criterios heurísticos, por lo que podrían existir combinaciones más convenientes dentro del presupuesto disponible. A futuro, se podría mejorar el modelo utilizando datos más comparables con los de prueba, calibrando las probabilidades y probando otros métodos de selección de préstamos. De esta manera, se buscaría obtener una cartera más rentable y lograr resultados más confiables al aplicar el modelo a nuevos casos.